

머신러닝 특성 공학 파이프라인 과제 보고서

학번: 2353658

이름: 강하람

1. 데이터셋 소개

본 과제는 Titanic 공개 데이터셋을 사용하여 생존 여부를 예측하는 이진 분류 문제를 다룬다.

- 데이터 출처: <https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv>
- 문제 유형: Classification (Survived: 0/1)
- 표본 수: 891개 (500개 이상 조건 충족)
- 변수 유형: 수치형 + 범주형 혼합

데이터 shape

- (891, 17)

주요 컬럼 설명

컬럼	설명
Survived	Target (0: no, 1: yes)
Pclass	Ticket class
Sex	Passenger sex
Age	Passenger age
SibSp	# siblings/spouses aboard
Parch	# parents/children aboard
Fare	Passenger fare
Embarked	Port of embarkation
FamilySize	Derived: SibSp + Parch + 1
IsAlone	Derived: 1 if FamilySize == 1
Title	Derived from Name
FarePerPerson	Derived: Fare / FamilySize
AgeGroup	Derived age bucket

2. EDA 결과

2.1 결측치 비율 분석

결측치 비율 분석 결과는 assignment_outputs/eda_missing_ratio.csv에 저장하였다.

대표적으로 Age, Cabin, Embarked에서 결측이 확인되었다.

결측치 비율(상위)

변수	결측 비율(%)
Cabin	77.10
AgeGroup	19.87

변수	결측 비율(%)
Age	19.87
Embarked	0.22

2.2 이상치 탐색

IQR 기준 이상치 탐색 결과는 assignment_outputs/eda_outlier_summary.csv에 저장하였다.

Fare 변수에서 상대적으로 이상치가 많이 관측되었다.


이상치 요약(IQR 기준)

변수	이상치 개수	이상치 비율
Age	11	0.0154
Fare	116	0.1302
SibSp	46	0.0516
Parch	213	0.2391
FamilySize	91	0.1021
FarePerPerson	69	0.0774


2.3 필수 시각화

- Histogram: assignment_outputs/figures/hist_age.png
- Boxplot: assignment_outputs/figures/boxplot_numeric.png
- Heatmap: assignment_outputs/figures/heatmap_corr.png
- Countplot: assignment_outputs/figures/countplot_target.png
- Barplot: assignment_outputs/figures/barplot_survival_by_pclass.png


Histogram (Age 분포)




Boxplot (수치형 주요 변수)




Heatmap (상관관계)



Countplot (타겟 분포)



Barplot (Pclass별 생존율)



위 시각화는 feature_engineering_assignment.py 실행 후 생성된 assignment_outputs/figures/*.png 파일을 본문에 직접 삽입한 것으로, 실제 실험 결과를 반영한다.

2.4 EDA 해석 요약

- 데이터 품질 문제: 결측치가 존재하며, Fare 등 일부 변수에 이상치가 존재한다.
- 불균형 여부: 타겟 클래스가 완전 균형은 아니나, 학습 불가능 수준의 극단적 불균형은 아니다.
- 주요 특징: Pclass, Sex, Fare, FamilySize 계열 변수는 생존과 유의미한 관계를 보인다.

3. Feature Engineering 과정

3.1 파생 변수 생성 (2개 이상)

본 실험에서 다음 파생 변수를 생성하였다.

- FamilySize = SibSp + Parch + 1
- IsAlone = FamilySize == 1 여부
- Title = Name 문자열에서 호칭 추출
- FarePerPerson = Fare / FamilySize
- AgeGroup = 나이 구간화

3.2 전처리 전략 비교

- 결측치 처리 비교: none(Base), mean(Exp-1), median(Exp-2), most_frequent(Exp-3)
- 범주형 인코딩 비교: none(Base), one-hot(Exp-1/3), label(Exp-2)
- 스케일링 비교: none(Base), standard(Exp-1), minmax(Exp-2), robust(Exp-3)

4. 변수 선택 (Feature Selection)

- 방법: Random Forest Feature Importance
- 상위 N개 변수: 12개
- 적용 실험: Exp-2, Exp-3
- 제거 전/후 성능 비교: before_fs vs after_fs로 비교

상세 중요도는 assignment_outputs/feature_importance_details.csv에 저장하였다.

선정 변수 목록은 assignment_outputs/selected_features_Exp-2.json, assignment_outputs/selected_features_Exp-3.json에 저장하였다.

5. 모델 학습 및 평가

5.1 비교 모델

- Logistic Regression
- Random Forest

5.2 평가 지표

- Accuracy

- Precision
- Recall
- F1-score
- ROC-AUC

5.3 필수 실험 조합표

실험	결측치 처리	인코딩	스케일링	Feature Selection
Base	없음	없음	없음	없음
Exp-1	Mean	One-Hot	Standard	X
Exp-2	Median	Label	MinMax	O
Exp-3	Most Frequent	One-Hot	Robust	O

5.4 성능 비교표

Experiment	Model	Stage	Accuracy	Precision	Recall	F1	ROC-AUC
Base	LogisticRegression	before_fs	0.7133	0.6977	0.5172	0.5941	0.7430
Base	RandomForest	before_fs	0.6503	0.5667	0.5862	0.5763	0.7001
Exp-1	LogisticRegression	before_fs	0.8324	0.8095	0.7391	0.7727	0.8777
Exp-1	RandomForest	before_fs	0.8101	0.7692	0.7246	0.7463	0.8300
Exp-2	LogisticRegression	before_fs	0.8101	0.7869	0.6957	0.7385	0.8486
Exp-2	LogisticRegression	after_fs	0.8101	0.7869	0.6957	0.7385	0.8486
Exp-2	RandomForest	before_fs	0.8156	0.7727	0.7391	0.7556	0.8405
Exp-2	RandomForest	after_fs	0.8156	0.7727	0.7391	0.7556	0.8318
Exp-3	LogisticRegression	before_fs	0.8324	0.8095	0.7391	0.7727	0.8773
Exp-3	LogisticRegression	after_fs	0.8045	0.7742	0.6957	0.7328	0.8627
Exp-3	RandomForest	before_fs	0.8268	0.8065	0.7246	0.7634	0.8313
Exp-3	RandomForest	after_fs	0.8324	0.7826	0.7826	0.7826	0.8291

6. 결과 해석 및 최종 결론

- 어떤 전처리 전략이 가장 효과적이었는가?
 - 본 실험에서는 Exp-3 조합에서 RandomForest + after_fs가 가장 높은 F1(0.7826)을 기록하였다.
- One-Hot Encoding이 항상 좋은가?
 - One-Hot은 Exp-1, Exp-3에서 우수했지만, 모델과 변수선택 조합에 따라 효과 크기는 달랐다. 즉 항상 절대적으로 우수하다고 단정할 수 없다.
- Feature Selection이 과적합 감소에 기여했는가?
 - Exp-2는 before/after 성능 차이가 거의 없었고, Exp-3의 RandomForest에서는 F1 개선(0.7634 → 0.7826)이 관찰되었다. 데이터/모델 조건에 따라 선택적으로 기여한다.
- 스케일링이 모델별로 어떤 영향을 미쳤는가?
 - Logistic Regression에서는 스케일링이 적용된 Exp-1/3에서 상대적으로 안정적인 성능을 보였다.

- RandomForest는 스케일링 민감도가 낮아, 인코딩/변수선택 영향이 상대적으로 크게 나타났다.

5. Feature Engineering이 실제 성능 향상에 얼마나 기여했는가?

- Base 대비 Exp 계열에서 전반적으로 성능이 향상되었으며, 특히 파생 변수와 인코딩/스케일링 조합을 적용한 설정에서 F1 및 ROC-AUC가 개선되었다.

7. 재현 방법

1. 스크립트 실행

- `python feature_engineering_assignment.py`

2. 생성 산출물 확인

- `assignment_outputs/report_draft.md`
- `assignment_outputs/experiment_results.csv`
- `assignment_outputs/result_summary_table.csv`
- `assignment_outputs/figures/₩*.png`

3. 제출용 PDF 작성

- 본 문서(과제특성공학보고서.md)를 PDF로 변환하여 제출

참고: 제출본 PDF에는 위 시각화 이미지와 표가 본문에 포함되어야 하며, 부록 파일 경로만 기재하는 방식은 감점 가능성이 있다.